Чеклист подготовки к практике 3

На практике сравним PostgreSQL и ClickHouse на разных объёмах данных, исследуем распределение в Greenplum и организацию таблиц в ClickHouse. Подготовьте стенд до занятия: первый запуск скачивает образы и загружает данные. В конце чеклиста собраны необязательные материалы для лучшего понимания тем практики.

1. Инструменты

Если Docker Desktop и DBeaver работают после предыдущих практик, переустанавливать их не нужно. Основная работа будет в DBeaver; Python и Jupyter не понадобятся.

☐ **Docker Desktop запущен.** В терминале выполняются docker version и docker compose version без ошибок.

☐ **DBeaver открывается.** При создании подключений доступны драйверы PostgreSQL и ClickHouse. Для Greenplum можно выбрать PostgreSQL. Если DBeaver предложит скачать драйвер, подтвердите загрузку.

2. Запуск и загрузка данных

☐ **Архив students.zip распакован целиком.** В папке students находятся compose.yaml, папка init и план Практика_3_план.md с запросами.

Откройте терминал в папке students и выполните:

```
docker compose up -d
docker compose logs -f init-clickhouse
```

☐ **В логах появилось сообщение Готово: 5000000|12500002500000|2501502250010.** Оно означает, что загрузка завершена и контрольные суммы совпали. Нажмите Ctrl+C, чтобы выйти из просмотра логов; базы продолжат работать.

3. Подключения в DBeaver

Создайте три подключения. Во всех системах база называется **shop**, адрес сервера - **localhost**.

Подключение	Драйвер	Порт	База	Пользователь	Пароль
PostgreSQL	PostgreSQL	5438	shop	student	studentpass
Greenplum	PostgreSQL	5439	shop	gpadmin	оставить пустым
ClickHouse	ClickHouse	8125	shop	student	studentpass

☐ **В каждом подключении выполнен запрос select 1;, получен ответ 1.** Если подключения остались от предыдущих занятий, проверьте порт и имя базы по таблице.

4. Проверка учебных таблиц

В PostgreSQL и ClickHouse выполните один и тот же запрос:

```
select count(*) from orders_large;
```

☐ **В обеих системах получено 5000000.**

В Greenplum выполните:

```
select count(*) from orders_source;
```

☐ **Получено 1000000.** Таблица находится в стандартной схеме public.

Если все пункты отмечены, стенд готов. После проверки его можно остановить командой docker compose stop из папки students. Перед занятием снова выполните docker compose up -d: данные сохранятся.

5. Рекомендованные материалы

Эти материалы не обязательны и нужны для закрепления теоретических материалов лекции. Можно выбрать отдельные темы, в которых хочется разобраться подробнее.

ClickHouse: парты, гранулы и ключ сортировки

Официальная документация ClickHouse на русском языке:

Материал	Что читать и зачем
Части таблицы	Как при вставке данных появляются отдельные парты, как они устроены и зачем ClickHouse объединяет их в фоне. Поможет отличать физическую часть таблицы (part) от партиции (partition).
Первичные индексы	Что такое гранулы и разреженный первичный индекс, как по условию запроса исключаются ненужные гранулы. Поможет понимать, почему поиск может читать больше одной строки и что показывают показатели Granules в explain indexes = 1.
Выбор первичного ключа	Как выбирать ключ под фильтры запросов и почему важен порядок столбцов в составном ключе. Связь с бизнес-задачами: поиск одного заказа по номеру и выборка заказов магазина за период могут требовать разных ключей.

Greenplum и родственные системы: архитектура и распределение данных

Официальная документация Arenadata на русском языке. Она описывает Arenadata DB (ADB). Для знакомства с общими принципами MPP-архитектуры, которые мы рассматриваем на примере Greenplum, эти материалы подходят; детали конкретных версий могут отличаться.

Материал	Что читать и зачем
Архитектура ADB	Введение и разделы «Мастер», «Сегменты», «Интерконнект»: кто принимает запрос, где хранятся данные и как сегменты работают параллельно. Есть схемы основных и зеркальных сегментов. Поможет понять, почему несколько сегментов могут работать на одном сервере.
Распределение данных	Политики distributed by, distributed randomly, distributed replicated и рекомендации по выбору ключа. Обратите внимание на равномерность распределения (skew — перекос) и размещение связанных строк на одном сегменте для локального, или co-location, JOIN. Это объясняет, зачем смотреть число строк по сегментам и перемещение данных в плане запроса.

Не является рекомендацией пользоваться продуктами Arenadata (лучше не надо), но документация хорошая.