СЕМИНАР ПО ЛЕКЦИИ 5 · МЕТОДИЧКА

Как запустить проект семинара: Git и Docker

ПЕРЕД НАЧАЛОМ

Что получится

```
ваш компьютер
├── Git     — скачивает проект с GitHub и сохраняет вашу работу
└── Docker  — запускает программы в контейнерах:
    ├── postgres  — рабочая (OLTP) база интернет-магазина, порт 5436
    ├── greenplum — хранилище, где лежит аналитический слой, порт 5440
    ├── loader    — при запуске копирует сырые таблицы из postgres в greenplum
    └── dbt       — строит витрины в greenplum
```

Устанавливать Python, PostgreSQL, Greenplum и dbt на компьютер **не нужно**: всё работает внутри Docker.

Что понадобится

Что	Зачем	Проверка
Git	Скачать проект и сдать домашку	`git --version`
Docker Desktop	Запустить базу и dbt	`docker compose version`
DBeaver	Смотреть таблицы в базе (уже есть с прошлых практик)	—
~5 ГБ свободного места, 8 ГБ оперативной памяти и интернет	Скачать образы при первом запуске. Образ Greenplum (~2 ГБ) у вас уже есть, если запускали практику 3	—

Все команды ниже вводятся в терминале:

- **macOS** — программа «Терминал»;
- **Windows** — PowerShell (Пуск → «PowerShell») или Git Bash;
- **Linux** — любой терминал.

УСТАНОВКА И ЗАПУСК

1 Установить Git

macOS. Выполните `git --version`. Если Git не установлен, macOS сама предложит поставить «инструменты разработчика». Согласитесь и подождите несколько минут.

Windows. Скачайте установщик с https://git-scm.com/download/win и пройдите установку, оставляя все настройки по умолчанию. Затем **закройте и снова откройте** PowerShell.

Linux (Ubuntu/Debian). `sudo apt install git`

Проверка: команда `git --version` печатает что-то вроде `git version 2.4x`.

2 Установить и запустить Docker Desktop

macOS. Скачайте Docker Desktop с https://www.docker.com/products/docker-desktop/. Выберите версию под свой процессор:

- **Apple Chip** — Mac на M1/M2/M3/M4;
- **Intel Chip** — более старые Mac.

Какой у вас процессор, видно в меню Apple (значок яблока в левом верхнем углу) → «Об этом Mac».

Windows. Скачайте Docker Desktop там же. При установке оставьте галочку **Use WSL 2**. Если установщик попросит обновить WSL, выполните в PowerShell **от имени администратора**:

```
wsl --install
```

После этого перезагрузите компьютер.

Linux. Подойдёт Docker Desktop или Docker Engine с плагином `docker compose`: https://docs.docker.com/engine/install/. Чтобы не писать `sudo` перед каждой командой, выполните `sudo usermod -aG docker $USER` и перезайдите в систему.

Запустите Docker Desktop. Дождитесь, пока внизу слева появится зелёная надпись **Engine running**. Docker Desktop должен быть запущен каждый раз, когда вы работаете с проектом.

Проверка:

```
docker --version
docker compose version
docker run --rm hello-world
```

Последняя команда должна напечатать `Hello from Docker!`.

3 Освободить ресурсы от прошлых стендов

В нашем стенде свой Greenplum. Если ещё работает стенд практики 3 (Greenplum + ClickHouse), два Greenplum одновременно могут не поместиться в память. Остановите старый стенд, данные при этом сохранятся:

```
cd <папка практики 3>
docker compose down
```

Или посмотрите, что сейчас запущено, и остановите всё сразу:

```
docker ps
docker stop $(docker ps -q)      # macOS / Linux / Git Bash
```

В PowerShell вместо последней команды используйте `docker ps -q | ForEach-Object { docker stop $_ }`.

4 Скачать проект

Перейдите в папку, где будете хранить учебные проекты. Надёжнее выбрать путь **без пробелов и кириллицы**, например `C:\study` или `~/study`:

```
mkdir study
cd study
git clone https://github.com/RKurbanova/store_hse.git
cd store_hse
```

Появится папка `store_hse` со всеми файлами проекта. **Все дальнейшие команды выполняются из этой папки.** Если терминал закрыли, вернитесь в неё: `cd study/store_hse`. Проверить, где вы находитесь, можно командой `pwd` (на Windows — `cd` без аргументов). В папке должен лежать файл `compose.yaml`.

5 Запустить базы и загрузить данные в хранилище

```
docker compose up -d
```

Команда запускает PostgreSQL и Greenplum, а когда обе базы готовы — сервис `loader`. Он копирует сырые таблицы магазина в Greenplum и завершается. При первом запуске скачиваются образы, это займёт несколько минут. Затем проверьте результат загрузки:

```
docker compose logs loader
```

Повторяйте команду, пока в конце не появится:

```
loader-1  | Готово: в Greenplum, база dwh, схема raw загружено строк:
loader-1  | orders 141
loader-1  | order_items 444
loader-1  | payments 160
loader-1  | customers 40
```

Состояние контейнеров показывает `docker compose ps -a`. `postgres` и `greenplum` должны быть `Up … (healthy)`, `loader` — `Exited (0)`: он отработал и остановился, так и должно быть.

6 Собрать dbt и проверить подключение

```
docker compose build dbt
docker compose run --rm dbt debug
```

Сборка образа в первый раз занимает 1–3 минуты. Повторно она не нужна. В конце вывода `dbt debug` должно быть:

```
All checks passed!
```

Готово — к семинару вы подготовились.

7 Подключить DBeaver

Создайте два подключения: **База данных** → **Новое соединение**. Тип — **PostgreSQL** для обоих: Greenplum понимает тот же протокол. Можно выбрать и тип Greenplum, если он есть в вашем DBeaver.

Параметр	OLTP (PostgreSQL)	DWH (Greenplum)
Хост	`localhost`	`localhost`
Порт	**`5436`**	**`5440`**
База данных	`shop`	`dwh`
Пользователь	`student`	`gpadmin`
Пароль	`studentpass`	пустой

Порты прошлых практик (5435, 5438, 5439) здесь не подходят.

Нажмите **Тест соединения** в каждом. В OLTP в схеме `public` должны быть таблицы `customers`, `orders`, `payments` и другие. В DWH в схеме `raw` должны быть их копии. Схемы `analytics_*` в DWH появятся после первого запуска dbt.

РАБОТА С ПРОЕКТОМ

Как писать команды dbt короче

Полная форма любой команды dbt — `docker compose run --rm dbt <команда>`. Например, `docker compose run --rm dbt run -s stg_shop__orders`. Можно один раз завести сокращение, и тогда писать просто `dbt run -s stg_shop__orders`.

macOS / Linux / Git Bash:

```
alias dbt="docker compose run --rm dbt"
```

Windows PowerShell:

```
function dbt { docker compose run --rm dbt @args }
```

Сокращение действует, пока открыт этот терминал. В новом окне его нужно ввести снова.

Каждый день: включить и выключить

Что сделать	Команда
Начать работу	Запустить Docker Desktop, перейти в папку `store_hse`, выполнить `docker compose up -d`
Закончить работу (данные сохранятся)	`docker compose down`
Заново загрузить сырые данные в Greenplum	`docker compose run --rm loader`
Начать с чистых баз (**удалит** все таблицы, которые построил dbt)	`docker compose down -v`, затем `docker compose up -d`

Ваш код хранится в файлах в папке `store_hse` и в Git, а не в базе. Поэтому `down -v` код не удаляет: после повторной загрузки следующий `dbt build` заново построит все витрины.

Сохранять работу в Git

После каждого законченного задания:

```
git add .
git commit -m "что сделано, например: staging-модели"
```

Если Git попросит представиться (`Please tell me who you are`), выполните один раз:

```
git config --global user.name "Имя Фамилия"
git config --global user.email "ваша@почта"
```

Как отправить работу в свой репозиторий на GitHub, описано в домашнем задании, раздел «Как сдавать». GitHub не принимает обычный пароль при `git push` . Вместо него нужен токен: github.com → Settings → Developer settings → Personal access tokens → Tokens (classic) → Generate new token с галочкой `repo` . Токен вставляется в ответ на запрос `Password` . Ещё проще работать через программу GitHub Desktop.

РЕШЕНИЕ ПРОБЛЕМ

Если что-то не работает

Сообщение	Причина	Что делать
`Cannot connect to the Docker daemon` / `error during connect`	Docker Desktop не запущен	Запустить и дождаться `Engine running`
`no configuration file provided: not found`	Команда выполнена не из папки `store_hse`	`cd` в папку, где лежит `compose.yaml`
`port is already allocated` / `address already in use`	Порт 5436 или 5440 занят, например стендом прошлой практики	Остановить старый стенд (шаг 3) или задать другие порты: `PG_PORT=5546 GP_PORT=5540 docker compose up -d` (в PowerShell: `$env:PG_PORT=5546; $env:GP_PORT=5540; docker compose up -d`) и указать их в DBeaver. Для dbt менять ничего не нужно
`docker compose logs loader` пустой или нет строки «Готово»	Greenplum ещё запускается	Подождать минуту и повторить. Если `loader` в `docker compose ps -a` в состоянии `Exited (1)` , прочитать ошибку в логе и выполнить `docker compose run --rm loader`
`greenplum` долго не становится `healthy` или перезапускается	Не хватает памяти	Закрыть лишние программы и стенды, в Docker Desktop → Settings → Resources выделить не меньше 4 ГБ памяти
dbt: `relation "raw.orders" does not exist`	Данные не загружены в Greenplum	`docker compose run --rm loader`
`Bind for 0.0.0.0:8080 failed` при `docs serve`	Порт 8080 занят	Добавить `DOCS_PORT=8081` перед командой `docker compose run … docs serve …` (в PowerShell: `$env:DOCS_PORT=8081;` перед командой) и открыть http://localhost:8081. Саму команду менять не нужно

Сообщение	Причина	Что делать
Сборка `docker compose build dbt` падает на `pip install`	Нет доступа к интернету или к PyPI	Проверить интернет, отключить VPN или прокси, повторить
`permission denied ... docker.sock` (Linux)	Пользователь не в группе `docker`	`sudo usermod -aG docker $USER` и перезайти
`WSL 2 installation is incomplete` (Windows)	Не установлен WSL	`wsl --install` от администратора, перезагрузка
`fatal: destination path 'store_hse' already exists`	Проект уже скачан	Перейти в существующую папку: `cd store_hse`
DBeaver: `password authentication failed` или нет таблиц	Подключение идёт к базе прошлой практики	Проверить порты: OLTP — **5436**, DWH — **5440**
`Could not connect to the database` в `dbt debug`	Greenplum ещё стартует	Подождать `(healthy)` в `docker compose ps` и повторить
dbt: `column "todo" does not exist`	В модели остались незаполненные `TODO`	Это нормально: заполните задание
Мало места на диске	Старые образы и тома	`docker system df` — посмотреть, `docker image prune` — удалить неиспользуемые образы

Не помогло — пришлите преподавателю текст ошибки целиком и вывод `docker compose ps`.

Запуск dbt без Docker (необязательно)

Базы всё равно запускайте через Docker (шаг 5). dbt можно поставить локально, если у вас Python **3.10–3.13**. На 3.14 dbt пока не работает.

```
python3.12 -m venv .venv
source .venv/bin/activate        # Windows: .venv\Scripts\activate
pip install -r requirements.txt
dbt debug
```

Файл `profiles.yml` dbt возьмёт из папки проекта; подключение по умолчанию — Greenplum на `localhost:5440`.